

# Report

Il progetto che vado a illustrare nasce nell'ambito del programma ANTIDOTE, dove prima codificato in XML-TEI e poi visualizzato tramite TEI Publisher il testo *Nota quod sacro concilio non est detrahendum* di Johannes Hildessen. Questo breve documento è stato scritto intorno al 1415 dal maestro boemo e costituisce una difesa formale del Concilio di Costanza e della sua suprema autorità all'interno della Chiesa. Nel contesto delle controversie hussite, Hildessen sosteneva la necessità di accettare le decisioni dei concili ecumenici e di non screditarli, in particolare per difendere il decreto conciliare che proibiva la comunione sotto entrambe le specie, cioè calice e ostia, ai laici.

Il lavoro svolto per l'esame di Computational Philology ha raccolto il materiale in questione per confrontare due dei sei testimoni manoscritti del testo: l'analisi si è concentrata su Prague D.54 e Wien 4941, limitatamente alla prima unità argomentativa del testo. Questa scelta ha permesso di lavorare su un confronto circoscritto, controllabile e adatto a una prima sperimentazione di strumenti digitali applicati all'analisi filologica.

La prima fase ha riguardato la preparazione del file XML-TEI, che ha richiesto alcune correzioni tecniche prima di poter essere elaborato in Python. In particolare, sono stati corretti problemi relativi agli identificatori XML, poiché un valore di `xml:id` iniziava con un numero e altri identificatori non erano unici. Successivamente sono state scelte come unità di confronto i sei segmenti argomentativi indicati con gli elementi TEI, riducendo il materiale dodici righe di dataset.

Innanzitutto, il workflow distingue tra `text_expanded` (con il testo in forma leggibile) e `text_normalized`, per il calcolo della similarità, che comprende la conversione in minuscolo, la rimozione della punteggiatura, la regolarizzazione degli spazi e la ricomposizione selettiva di parole divise graficamente o a fine riga.

Come prima analisi ho svolto una *similarity evaluation* che confronta i segmenti corrispondenti nei due testimoni attraverso due misure: Jaccard similarity e Longest Common Subsequence similarity, per indagare la condivisione di lessico e la stabilità della struttura testuale. I risultati mostrano che gli argomenti 6, 4 e 2 sono i più stabili, con valori alti sia per Jaccard sia per LCS. Gli argomenti 1, 3 e 5 presentano invece situazioni più problematiche: l'argomento 1 è molto breve e quindi sensibile anche a piccole variazioni; l'argomento 3 mostra un alto overlap lessicale ma una minore similarità sequenziale, perché D54 conserva una formulazione più estesa; l'argomento 5 mantiene una sequenza riconoscibile ma presenta differenze lessicali e materiale aggiuntivo in 4941.

A queste misure è stata affiancata per completezza anche la Levenshtein distance a livello di token, che conferma quanto già detto. È stato inoltre realizzato un allineamento esplorativo dell'argomento 3, che mostra come D54 conservi materiale assente in 4941, in particolare la parte relativa alla condanna delle eresie.

Infine, le varianti sono state classificate manualmente secondo categorie linguistiche e filologiche: variazione grafica o ortografica, variazione morfologica, variazione lessicale, aggiunta, omissione o compressione e variazione nell'ordine delle parole. Questa fase permette di collegare i risultati computazionali a un'interpretazione qualitativa delle differenze tra i testimoni.

Il progetto presenta limiti evidenti, soprattutto per la dimensione ridotta del dataset e per il carattere manuale della classificazione delle varianti. Tuttavia, dimostra come strumenti computazionali e analisi

filologica possano integrarsi: le misure quantitative non sostituiscono la lettura critica, ma aiutano a individuare pattern di stabilità e divergenza tra i testimoni, costituendo un primo passo verso una possibile edizione critica digitale.